ATTITUDE IS EVERYTHING

MODUL AJAR

Koding dan Kecerdasan Artificial

Rekayasa Perangkat Lunak

SMK Telkom Malang

Prepared By:

MGMP RPL

FASE F
KELAS XI

Exploratory Data Analysis (EDA) dengan NumPy & Pandas

A. Tujuan Pembelajaran

Setelah mempelajari modul ini, siswa diharapkan mampu:

1. Memahami dan menggunakan library NumPy untuk operasi array dasar.
2. Memahami dan menggunakan library Pandas (Series & DataFrame).
3. Melakukan Data Loading dan Data Inspection terhadap sebuah dataset.
4. Melakukan Data Cleaning: menangani missing value, duplikat, dan tipe data yang tidak sesuai.
5. Melakukan Data Manipulation: filtering, sorting, grouping, dan membuat kolom turunan.
6. Merancang dan menyelesaikan proyek EDA secara berkelompok, dari data mentah hingga dataset siap dianalisis.

B. Dasar Teori

1. Apa itu NumPy dan Pandas ?

NumPy (Numerical Python) adalah library Python untuk melakukan operasi numerik secara cepat pada data berbentuk array (kumpulan angka multi-dimensi).

Kenapa tidak pakai list Python biasa? List Python fleksibel tapi lambat untuk operasi matematis pada data besar, dan tidak bisa langsung dioperasikan sebagai satu kesatuan.

```
# List Python biasa - harus looping
harga = [10000, 15000, 8000]
harga_diskon = [h * 0.9 for h in harga]

# NumPy array - operasi langsung ke seluruh data sekaligus
import numpy as np
harga = np.array([10000, 15000, 8000])
harga_diskon = harga * 0.9   # tidak perlu loop
```

Analogi: List Python seperti menghitung diskon belanja satu-satu pakai kalkulator manual. NumPy array seperti mesin kasir yang bisa memproses seluruh struk sekaligus dalam satu perintah.

Fungsi NumPy yang sering dipakai dalam EDA:

- np.mean() — menghitung rata-rata
- np.median() — menghitung nilai tengah
- np.std() — menghitung standar deviasi (sebaran data)
- np.min() / np.max() — mencari nilai terkecil/terbesar

Pandas adalah library Python yang dibangun di atas NumPy, dipakai untuk mengolah data tabular (berbentuk tabel, seperti Excel/spreadsheet) — inilah tool utama untuk EDA (Exploratory Data Analysis).

Dua struktur data inti:

- Series — satu kolom data (mirip satu kolom di Excel)
- DataFrame — tabel lengkap dengan banyak kolom (mirip satu sheet Excel)

```
import pandas as pd

# DataFrame - seperti tabel Excel di dalam Python
df = pd.read_csv("dataset_penjualan_kantin.csv")

df.head()      # lihat 5 baris pertama
df.info()      # lihat tipe data & jumlah data tiap kolom
df.describe()  # lihat statistik ringkas (rata-rata, min, max, dst)
```

Analogi: Kalau NumPy adalah mesin kalkulasi angka, Pandas adalah "Excel di dalam kode" — bisa baca file (CSV/Excel), menyaring baris, mengurutkan, menghitung rata-rata per kelompok, dan membersihkan data kotor, semuanya lewat baris kode yang bisa diulang otomatis.

Pandas memakai NumPy di balik layar untuk perhitungan numeriknya — jadi keduanya biasanya diimpor bersamaan (import numpy as np dan import pandas as pd), meski dalam praktik EDA porsi pemakaian Pandas jauh lebih besar daripada NumPy secara langsung.

2. Mengapa Butuh NumPy dan Pandas?

Python standar (list, dictionary) kurang efisien untuk mengolah data dalam jumlah besar. NumPy dan Pandas adalah library yang dirancang khusus untuk komputasi numerik dan tabel data secara cepat dan ringkas.

Analogi Buku Excel: Jika Pandas DataFrame diibaratkan satu lembar kerja (sheet) Excel, maka setiap kolomnya adalah Pandas Series, dan seluruh angka murni yang diproses di baliknya memanfaatkan NumPy Array.

SMK Telkom Malang

2. NumPy Array Dasar

```
import numpy as np

nilai = np.array([80, 75, 90, 60, 88])
print(nilai.mean())      # rata-rata
print(nilai.max())       # nilai tertinggi
print(nilai * 2)         # operasi langsung ke semua elemen (vectorized)
```

3. Pandas Series & DataFrame

```
import pandas as pd

data = {
    'nama': ['Andi', 'Budi', 'Citra'],
    'nilai': [80, 75, 90]
}
df = pd.DataFrame(data)
print(df)
```

4. Alur Kerja EDA (Exploratory Data Analysis)

- Data Loading – memuat data dari sumber (CSV, Excel, database) ke dalam DataFrame.
- Data Inspection – mengenali struktur data: jumlah baris/kolom, tipe data, dan sebaran nilai.
- Data Cleaning – menangani data hilang, duplikat, dan tipe data yang tidak sesuai.

- Data Manipulation – menyaring, mengurutkan, mengelompokkan, dan membuat kolom turunan untuk menjawab pertanyaan analisis.

C. Latihan Praktikum Bertahap (Scaffolding)

Kerjakan latihan berikut secara berurutan menggunakan dataset contoh “Data Penjualan Kantin Sekolah”, lalu terapkan teknik yang sama pada dataset proyek kelompok kalian.

Latihan 1: Operasi Dasar NumPy Array

```
import numpy as np

harga = np.array([5000, 7000, 3000, 12000, 4500])
print('Rata-rata harga:', harga.mean())
print('Harga tertinggi:', harga.max())
print('Harga setelah diskon 10%:', harga * 0.9)
```

Tugas Analisis 1: Bandingkan hasil harga * 0.9 di atas dengan jika harga berupa list Python biasa (bukan array). Apa yang terjadi bila kamu mencoba [5000,7000,3000] * 0.9? Jelaskan mengapa berbeda.

Latihan 2: Membuat Series & DataFrame

```
import pandas as pd

data_kantin = {
    'menu': ['Nasi Goreng', 'Es Teh', 'Mie Ayam', 'Es Teh', None],
    'harga': [12000, 4000, 10000, 4000, 8000],
    'terjual': [23, 40, None, 35, 18]
}
df = pd.DataFrame(data_kantin)
print(df)
```

Tugas Analisis 2: Amati tabel yang dihasilkan. Kolom mana yang terlihat memiliki data kosong (None)? Menurutmu apa risikonya jika data ini langsung dianalisis tanpa dibersihkan?

Latihan 3: Data Loading & Inspection

```
df = pd.read_csv('data_kantin.csv')

print(df.head())        # 5 baris pertama
print(df.info())        # tipe data & jumlah non-null tiap kolom
print(df.describe())    # statistik ringkas kolom numerik
print(df.shape)         # jumlah (baris, kolom)
```

Tugas Analisis 3: Dari hasil df.info(), kolom mana yang jumlah non-null-nya lebih sedikit dari jumlah baris total? Apa artinya?

Latihan 4: Menangani Missing Value

```
print(df.isnull().sum())            # jumlah data kosong tiap kolom

df['terjual'] = df['terjual'].fillna(0)          # isi kekosongan dengan 0
df = df.dropna(subset=['menu'])                   # hapus baris jika kolom menu kosong
```

Tugas Analisis 4: Mengapa pada contoh di atas kolom terjual diisi (fillna) sedangkan baris dengan menu kosong justru dihapus (dropna)? Diskusikan alasan logisnya.

Latihan 5: Menangani Duplikat dan Tipe Data

```
print(df.duplicated().sum())        # jumlah baris duplikat
df = df.drop_duplicates()

df['harga'] = df['harga'].astype(int)   # memastikan tipe data harga adalah integer
print(df.dtypes)
```

Tugas Analisis 5: Setelah drop_duplicates(), berapa jumlah baris dataset sekarang dibanding sebelumnya? Mengapa penting memastikan tipe data (dtypes) sudah benar sebelum data dianalisis lebih lanjut?

Latihan 6: Data Manipulation (Filtering, Sorting, Groupby)

```
laris = df[df['terjual'] > 20]                      # filtering
urut = df.sort_values(by='terjual', ascending=False)  # sorting

df['total_pendapatan'] = df['harga'] * df['terjual']  # kolom turunan

ringkasan = df.groupby('menu')['total_pendapatan'].sum()  # agregasi
print(ringkasan)
```

Tugas Analisis 6: Dari hasil groupby di atas, menu apa yang menghasilkan total_pendapatan tertinggi? Bagaimana informasi ini bisa membantu pengambilan keputusan di kantin sekolah?

D. Lembar Perencanaan Proyek Kelompok (Project Charter)

Isi bersama kelompok sebangkumu dan perbarui sepanjang proyek:

Jika Kalian menggunakan Google Colabs bisa langsung ditambahkan isian ini ke Text atau Komentar jika menggunakan VS Code.

Nama Anggota Kelompok	1. ..... 2. .....
Dataset yang Dipilih	□ Data Penjualan Kantin/Toko □ Data Nilai Akademik Siswa □ Data Sensor IoT Sederhana □ Dataset lain: .....
Pertanyaan Analisis Awal	1. ..... 2. ..... 3. .....
Dugaan Masalah Kualitas Data	□ Missing value pada kolom: ..... □ Duplikat data □ Tipe data tidak sesuai pada kolom: ..... □ Lainnya: .....
Rencana Teknik Pembersihan	.....
Rencana Manipulasi Data	Filter: ..... | Sort: ..... | Kolom turunan: ..... | Groupby/agregasi: .....
Jadwal Kerja	P3 (Loading & Inspection): ..... | P4 (Cleaning): ..... | P5 (Manipulation): ..... | P6 (Uji & Presentasi): .....

Pembagian Peran	Anggota 1: ..... | Anggota 2: .....

E. Proyek Akhir: EDA Starter Project

Terapkan seluruh tahapan Data Loading, Inspection, Cleaning, dan Manipulation pada dataset proyek kelompok kalian (lihat Project Charter D).

Ketentuan Teknis Wajib

- Data Loading & Inspection: memuat dataset dan menampilkan head(), info(), describe(), dan shape sebagai bagian awal notebook.
- Data Cleaning: menangani seluruh missing value dan duplikat yang ditemukan, disertai catatan alasan teknik yang dipilih (fillna vs dropna, dsb.), serta memastikan tipe data setiap kolom sudah sesuai.
- Data Manipulation: melakukan minimal 1 filtering, 1 sorting, 1 kolom turunan, dan 1 groupby/agregasi yang relevan dengan pertanyaan analisis awal proyek.
- Data Profiling Summary: menuliskan ringkasan 2–3 temuan awal dalam bentuk narasi singkat (bukan hanya angka mentah) sebagai bahan presentasi.

Alur Kerja Proyek

1. Muat dataset dan lakukan inspeksi awal untuk mengenali struktur dan masalah data.
2. Bersihkan data sesuai checklist masalah yang ditemukan (missing value, duplikat, tipe data).
3. Olah data (filter/sort/groupby/kolom turunan) untuk mulai menjawab pertanyaan analisis awal.
4. Simpan dataset bersih (mis. df.to_csv('dataset_bersih.csv')) sebagai bahan Elemen 3 (Visualisasi Data).
5. Susun ringkasan temuan awal dan presentasikan hasil proyek.

SMK Telkom Malang

B.7 Lembar Refleksi Proyek

Isi secara kelompok setelah menyelesaikan tahapan proyek akhir.

6. Tahap mana (loading, inspection, cleaning, atau manipulation) yang paling menantang bagi kelompokmu, dan bagaimana kalian mengatasinya?
7. Menurutmu, mengapa keputusan membersihkan data (mis. menghapus vs mengisi data kosong) perlu didasarkan pada alasan yang jelas, bukan asal-asalan?
8. Apa hubungan antara dataset bersih hasil proyek ini dengan pekerjaan seorang Data Analyst di dunia nyata?

F. Rangkuman Istilah

Istilah	Penjelasan Singkat
NumPy Array	Struktur data numerik yang mendukung operasi vectorized (efisien)
Pandas Series	Struktur data 1 dimensi (mirip satu kolom tabel)
Pandas DataFrame	Struktur data 2 dimensi berbentuk tabel (baris & kolom)
Data Loading	Proses memuat data dari sumber eksternal ke dalam program
Data Inspection	Mengenali struktur, tipe data, dan sebaran nilai suatu dataset
Missing Value	Data yang hilang/kosong pada suatu sel
Data Duplikat	Baris data yang muncul lebih dari satu kali secara identik
Filtering	Menyaring data berdasarkan kondisi tertentu
Groupby / Agregasi	Mengelompokkan data lalu meringkasnya (sum, mean, count, dsb.)

~ Selamat Mengeksplorasi Data! ~

SMK Telkom Malang